

<기초통계 과제 보고서>

2024148094 민신원

Part 1. 고객 이해 (EDA)

1. 데이터 구조 및 요약

DailyBox의 데이터는 총 6,000명의 고객 스냅샷으로 걸쳐지는 존재하지 않습니다. 핵심 타겟 변수인 월 구매액(monthly_spend)은 8.26달러에서 최대 288.44달러까지 분포하며, 평균은 약 32.27달러입니다.

2. 매출 분포와 로그변환

월 구매액의 왜도(Skewness)는 약 2.55로 나타나, 오른쪽으로 꼬리가 긴(Right-skewed) 형태를 띠니다. 이는 소수의 '고가치 고객'에게 전체 매출이 크게 쏠려 있음을 의미합니다. 이러한 데이터에 log1p 변환을 적용하면 분포의 비대칭성이 완화되어 정규분포에 가까워지므로, 선형 회귀와 같은 통계 모델의 성능과 가정을 충족하는 데 큰 도움이 됩니다.

3. 채널·등급별 매출 시각화

유입 채널 중에서는 'Influencer(인플루언서)' 채널로 들어온 고객의 구매액이 가장 높아 핵심 고가치 채널로 판단되며, 반대로 'Social Ads(소셜 광고)' 채널은 상대적으로 매출이 낮습니다. 멤버십 등급의 경우 등급이 올라갈수록(Basic < Silver < Gold) 월 구매액의 중앙값과 범위가 확연히 증가하여 뚜렷한 고가치 고객군임을 보여줍니다.

Part 2. 가정 확인

4. 1종/2종 오류의 비즈니스적 의미

"쿠폰 캠페인은 매출에 효과가 없다"는 귀무가설(H_0) 하에서:

1종 오류: 실제로는 효과가 없는데 쿠폰이 효과가 있다고 잘못 판단하는 오류입니다. 이는 무의미한 쿠폰 남발로 인한 마케팅 예산 및 마진 낭비를 초래합니다.

2종 오류: 실제로는 쿠폰 효과가 있음에도 효과가 없다고 판단하여 캠페인을 중단하는 오류입니다. 이는 캠페인을 통해 얻을 수 있었던 잠재적 매출 증대 기회의 손실을 의미합니다.

5. 정규성 검정 (Shapiro-Wilk)

원본 매출 데이터에 대한 정규성 검정 결과, p-value가 0.05보다 매우 작아($3.63e-21$) 정규성 가정을 기각합니다. 하지만 로그 변환(log1p) 후에는 p-value가 여전히 0.05 미만인 하나, 검정 통계량(statistic)이 0.853에서 0.987로 상승하여 분포가 정규성에 가깝게 크게 개선됨을 확인했습니다.

6. 등분산성 검정 (Levene)

유입 채널 4개 그룹 간의 Levene 검정 결과 p-value가 0.05보다 현저히 작게 나타났습니다. 이는 채널 간 매출 분산이 동일하지 않음(이분산성)을 의미하므로, 이후 ANOVA 검정 등에서 등분산 가정이 위배되었음을 인지하고 Welch's test 등의 대안을 고려해야 함을 시사합니다.

Part 3. 집단 비교 검정

7. 쿠폰 캠페인의 효과 검증 (t-test)

귀무가설(H_0)을 '발송군과 미발송군 간의 매출 차이가 없다'로 설정했습니다. Welch's t-test 결과, p-value가 유의수준 0.05보다 현저히 작아 귀무가설을 기각합니다. 쿠폰을 발송한 그룹(Treatment)의 평균 매출이 34.8달러로 대조군(Control, 29.7달러)보다 유의미하게 높았으므로, 다음 분기에도 캠페인을 지속해야 합니다.

8. 채널 비교 (ANOVA & Tukey HSD)

유입 채널별 매출 평균 차이를 확인한 ANOVA 결과가 유의하였고, Tukey 사후검정 결과 인플루언서(Influencer) > 추천(Referral) > 오가닉(Organic Search) > 소셜 광고(Social Ads) 순으로 평균 매출에 유의미한 차이가 있었습니다. 따라서 통계적으로 인플루언서 채널이 가장 고가치 고객을, 소셜 광고 채널이 저가치 고객을 데려옵니다.

9. 교호작용 (Two-way ANOVA)

채널과 캠페인 발송 여부에 대한 Two-way ANOVA 결과, 두 주효과뿐만 아니라 교호작용 (Interaction) 항목의 p-value도 유의하게 나타났습니다. 즉, 유입 채널별로 쿠폰 캠페인에 반응하여 매출이 증대되는 민감도(효과)의 크기가 다르게 나타남을 의미합니다.

Part 4. 회귀분석

10. 단순/다중 회귀분석 및 레버 해석

단순회귀(방문 횟수)의 Adjusted R^2 (0.053)보다 여러 요인을 추가한 다중회귀의 Adjusted R^2 (0.216)가 더 높아 모형의 설명력이 개선되었습니다. 다중회귀 계수 확인 결과 방문 횟수, 평균 할인율, 광고비 모두 통계적으로 유의미한 양(+)의 기여를 했습니다. 특히 할인율(11.42)의 계수가 크므로 할인 혜택 확대는 훌륭한 매출 전략입니다. 채널 더미 변수 중 Social Ads 등의 계수가 큰 음수(-)를 기록한 것은 기준 범주인 Influencer 대비 매출이 크게 떨어진다는 뜻으로, 8번의 결론과 일치합니다.

11. 다중공선성(VIF) 진단

total_ad_cost 변수를 포함할 경우 해당 변수와 온/오프라인 광고비 변수들의 VIF가 무한대(inf)로 나타납니다. 이는 total_ad_cost가 online_ad_cost + offline_ad_cost라는 정의상 수식으로 계산된 완벽한 선형 결합을 이루기 때문입니다. total_ad_cost를 모형에서 제거하면 나머지 변수의 VIF가 1에 가깝게 떨어지며 문제가 해결됩니다.

12. 잔차 진단

원본 매출 데이터를 종속변수로 사용한 모형의 잔차 Q-Q plot과 산점도는 양 끝에서 가정을 크게 위반하며 깔때기 모양의 이분산성을 띕니다. 그러나 종속변수를 log1p 변환한 모형에서는 잔차가 정규분포 직선에 훨씬 가깝게 붙고 분산도 고르게 흩어져 회귀 분석의 가정을 훨씬 잘 충족하게 됩니다.

Part 5. 타겟팅

13~14. 로지스틱 회귀와 오즈비(Odds Ratio) 해석

캠페인 반응 여부를 예측하는 로지스틱 회귀 결과, 캠페인 발송 여부와 멤버십 등급의 오즈비가 모두 1보다 크게 나타났습니다. 이는 쿠폰이 발송된 고객일수록, 그리고 멤버십 등급이 상위(Silver, Gold)일수록 전환(반응)할 확률이 배수로 증가함을 의미합니다. 따라서 다음 캠페인은 반응 확률이 가장 높은 기존 고등급 멤버십 고객들에게 타겟팅을 집중해야 합니다.

[종합 결론] CMO 보고용 마케팅 전략 제안

1. 캠페인 지속 여부: 적극적인 캠페인 유지 권장

분석 결과(t-test 및 로지스틱 회귀) 쿠폰을 받은 고객의 월평균 매출(34.8달러)이 대조군(29.7달러)보다 통계적으로 확실하게 높았고 전환 확률도 뛰어났습니다. 쿠폰 발송이 매출 상승으로 직결되는 것을 데이터로 확인했으니 다음 분기에도 캠페인을 중단 없이 끌고 가야 합니다.

2. 채널 예산 배분: '인플루언서'와 '레퍼럴' 채널로 예산 이동

우리 DailyBox에 진짜 돈이 되는 고가치 고객은 '인플루언서(Influencer)'와 '추천(Referral)'을 통해 유입되고 있습니다. 반면 '소셜 광고(Social Ads)'는 통계적으로 가장 저가치 고객을 데려오는 것으로 드러났습니다. 과감하게 소셜 광고 예산을 덜어내어 인플루언서 채널 쪽에 태우는 '선택과 집중'이 필요합니다.

3. 핵심 매출 레버: 앱 방문 횟수 증가와 타겟팅 할인

회귀분석 결과, 단순 광고비 지출보다는 고객의 '방문 횟수'와 '할인율'이 매출을 올리는 가장 강력한 무기(레버)였습니다. 예산을 무작정 매체에 태우기보다는, 고객이 앱에 자주 들어오게끔 푸시 알림이나 게이미피케이션(출석체크 등) 요소를 기획하고 적절한 타이밍에 할인 프로모션을 쏘아넣어 결제를 유도하는 것이 효과적입니다.

4. 타겟팅: '충성도 높은 Silver/Gold 등급' 우선 공략

오즈비 분석을 통해 고객의 등급이 오를수록 마케팅 반응률이 급상승한다는 것을 파악했습니다. 한정된 쿠폰 발송 예산을 효과적으로 쓰려면, 아직 활동이 저조한 신규/Basic 고객보다는 이미 락인(Lock-in)되어 있는 Silver 및 Gold 등급 고객들에게 쿠폰을 쏘서 구매 단가를 높이는 데 집중해야 합니다.

5. 데이터 분석의 한계점

스냅샷 데이터의 한계: 이번 데이터는 딱 한 달 치를 잘라본 거라서, 연간 트렌드나 계절성, 긴 호흡의 고객 생애 가치(LTV)까지 전부 반영하지는 못했다는 점을 고려해야 합니다.

다중공선성 처리: 광고비 관련 변수 간에 식($\text{total} = \text{online} + \text{offline}$)이 완전히 겹치는 공선성 문제가 있었지만 변수를 제거해 모형을 안정화했습니다.

인과관계 해석 주의: 데이터상 할인율이 높을수록 매출이 컸지만, "할인을 해서 매출이 오른 것"인지 "원래 많이 사는 사람이라 할인을 많이 받은 것"인지는 명확히 구분하기 어렵습니다. 앞으로 프로모션 규모를 키우기 전, 마진을 방어하기 위한 A/B 테스트로 추가적인 인과성 점검을 해보는 것을 권장합니다.